제4회 유통데이터 활용 경진대회
(수요예측 부문) 분석보고서 요약서

1. 팀명 : Nexus

2. 세부내용

ㅇ 분석 주제

품목 분류별별 특성 기반 수요 예측을 통한 재고 비용 최소화 전략 수립

ㅇ 분석 목적

다양한 예측 모델 비교를 통해 품목별 최적 수요 예측 모델을 선정한다. 이를 재고 관리 이론과 결합하여 최적 매입량을 도출함으로써, 재고 비용을 최소화하고 운영 효율성을 극대화하는 전략 수립에 기여하는 것을 목적으로 한다.

ㅇ 핵심 내용

데이터 통합 및 전처리: A/B 물류센터의 매출·매입 데이터 및 상품 마스터 데이터를 통합하여 분석 기반 마련.
수요 예측 모델링, 매출 예측: 품목군별(생수·음료, 신선식품 등) 특성을 고려하여 SARIMA, Prophet 등 다양한 시계열 모델의 성능(RMSE)을 롤링 예측 방식으로 비교 검증하여 최적 모델 선정 및 예측치 산출.

최적 매입량 산출: 예측된 판매량을 기반으로, 데이터에서 추정한 리드타임(L)과 발주주기(R)를 활용. 품목별 수요 변동계수(CV)와 목표 서비스 수준(z)을 고려하여 동적 안전재고(Safety Stock)를 계산하고, 일별 재고 시뮬레이션을 통해 최종 최적 매입량을 산출.

ㅇ 기대효과

동적 안전재고 도입: 과거 경험이 아닌 월별 예측 판매량에 연동되는 동적 안전재고 시스템을 도입하여 과잉/부족 재고 최소화.
발주 자동화 및 비용 절감: 산출된 발주점(ROP)과 최적 매입량을 시스템화하여 발주를 자동화하고, 이를 통해 재고 유지 비용 및 품절로 인한 기회비용 절감.
규모의 경제 실현: 계절적 수요가 큰 품목(예: 음료)에 대한 정확한 예측을 바탕으로 대량 매입을 진행하여 구매 단가 인하..

ㅇ 활용데이터 및 참고 문헌 출처

활용데이터:
A물류센터 매입 2021~2024, A물류센터 매출 2021~2024, B물류센터 매입 2021~2024, B물류센터 매출 2021~2024, 상품정보_가공식품, 상품정보_신선식품, 서울시 월누적 강수량, 서울시 월별 평균기온, 서울시 소비자물가지수(지출목적별) 통계

참고문헌:
김용철 외(2019), 「기상요인이 음료 소비에 미치는 영향 분석」, 한국식품유통학회지.
“The impact of systematic changes in weather on the supply and demand of beverages” (Keleş, Gómez-Acevedo, Shaikh, International Journal of Production Economics, 2018) 서은석. (2015). 정책적 안전재고의 비용 최적화 : 제록스 소모품 유통공급망 사례연구. 대한산업공학회지, 41(5), 511-520.

제4회 유통데이터 활용 경진대회
(수요예측부문) 분석보고서

1. 팀명 : Nexus

2. 세부내용

◦ 분석 개요

본 분석의 최종 목표인 재고 부족과 과잉 재고 문제를 최소화하는 전략을 수립하기 위해서 정확한 수요 예측이라는 선결과제 수행이 필수적이었다. 각 품목 분류별 특징을 파악하고 개별 특징에 맞는 분석 방법을 적용해 최적 매출/매입량을 예측해야 했다. 그러므로 데이터의 특성에 가장 적합한 예측 모델을 찾아내는 것을 분석의 핵심 방향성으로 설정했다.

최적의 매입량을 산출하기 이전에, 특정 월의 최적 판매량을 예측하는 것이 선행되어야 했다. 또한, 각 품목 분류별 수요의 특징을 고려하기 위해 다양한 예측 모델을 적용하며 각 특징에 맞는 모델을 탐색했다. 매출 데이터의 내재적 특징과 외부 변수들을 반영하여 SARIMA, SARIMAX, LightGBM, Seasonal Naive, Holt-Winters 등 다양한 모델링 기법을 비교 검증했다.

이를 바탕으로 최종적으로 도출된 최적 판매량 예측치에 재고 관리 이론을 적용하여 최적 매입량을 산출하였다. 매입량 또한 품목 분류별 최적의 목표 서비스 수준, 수요 변동계수, 리드타임 등을 고려하여 예측했다. 데이터 기반의 접근에만 국한되지 않고 유통 상품 재고의 효율적인 관리를 위한 안전재고 수준과 그에 맞는 발주량을 도출함으로써, 실질적인 물류운영에 적용 가능한 전략을 수립하는데 의의가 있다.

◦ 분석 방법 및 절차

<판매량 예측>

1. 데이터 확인 및 전처리

분석에 앞서 데이터를 확인한 결과, 두 가지 주요 문제점을 발견했다. 첫째, 일부 행에서 중분류 값이 결측(NaN)되어 있었고, 둘째 파일 간 열 이름이 서로 달라 일관성 확보가 필요했다.

결측치 처리를 위해 바코드의 구조를 사용했다. 바코드의 마지막 자리는 계산식에 의해 결정되는 체크 디짓으로 동일한 상품이어도 옵션이 다르면 첫 번째 바코드 번호에 따라 마지막 자리가 달라지는 것을 확인했다.

이에 따라 바코드의 중간 12자리 숫자를 실제 상품을 식별하는 주요 코드로 활용하였으며, 이를 기반으로 중분류 결측값을 매핑하여 보완했다.

이후 통합된 데이터셋에서 열 이름을 통일하고, 중분류, 소분류를 기준으로 상품을 카테고리별로 분류했다.
전처리를 통해 데이터의 일관성을 확보하였고, 이후 단계에서 시계열 생성 및 예측 모델링을 수행할 수 있는 기반을

마련했다.

2. 시계열 데이터 구성 및 분석 준비

전처리된 데이터를 기반으로 월별 판매수량 시계열을 생성했다. 분석 목적에 맞게 일별 데이터를 월 단위로 집계하여 각 카테고리별로 독립된 시계열을 구성했다. 일부 모형에서는 판매수량의 분포를 안정화하기 위해 1~99% 구간으로 극단값을 제한하고, 로그 변환을 적용하여 예측 안정성을 개선했다. 또한 특정 비정상적인 구간은 중앙값대체를 활용하여 패턴 왜곡을 완화했다.

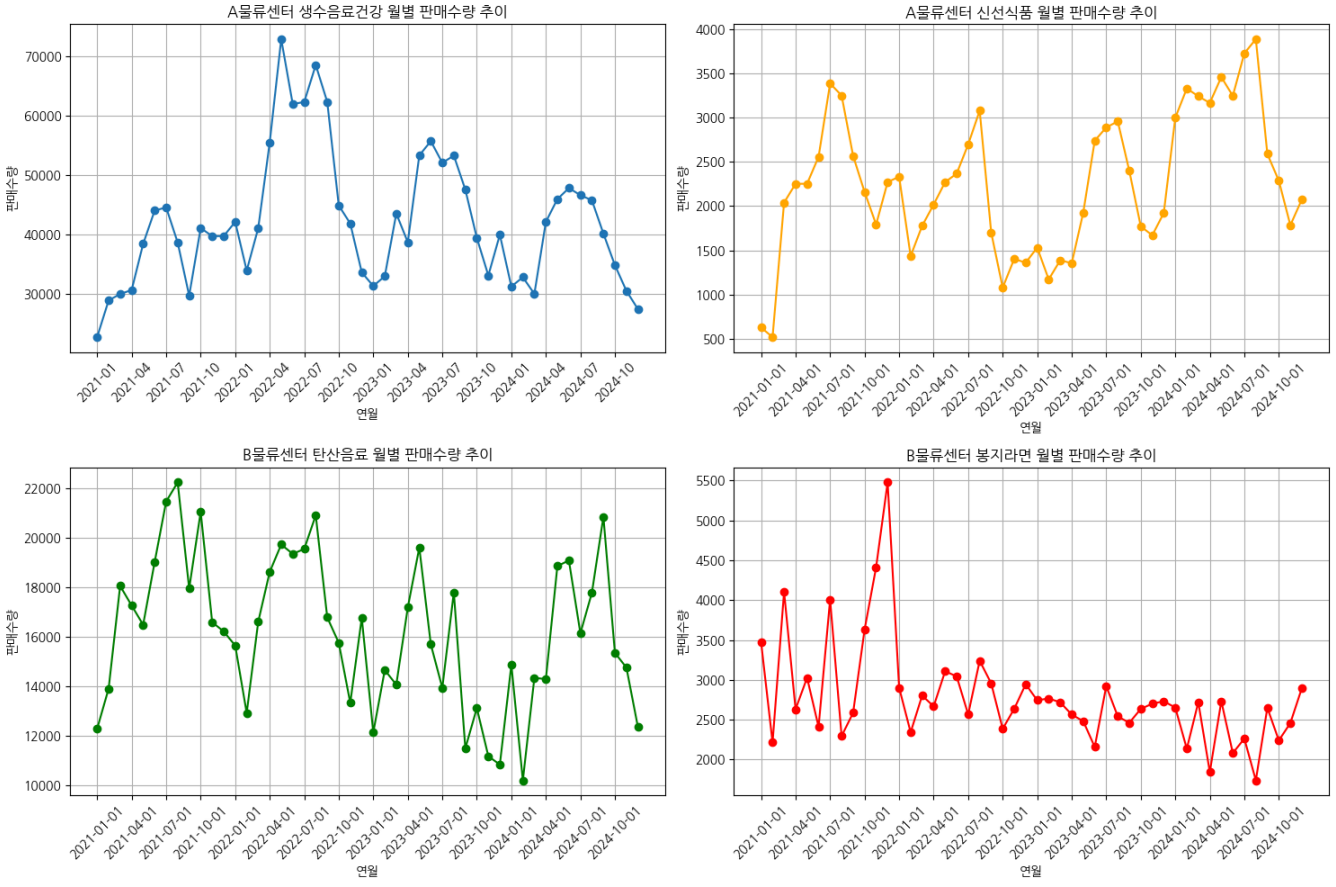
모형에 따라 월별 공휴일 수, 설날·추석 더미, 직전년도 평균 기온, 최고 기온등을 외생변수로 추가하여 계절성과 외부 요인을 반영하고자 했다.

최종적으로 카테고리별로 '연월', '판매수량' 형태의 시계열 데이터를 구성하여 모델 학습에 활용했다.

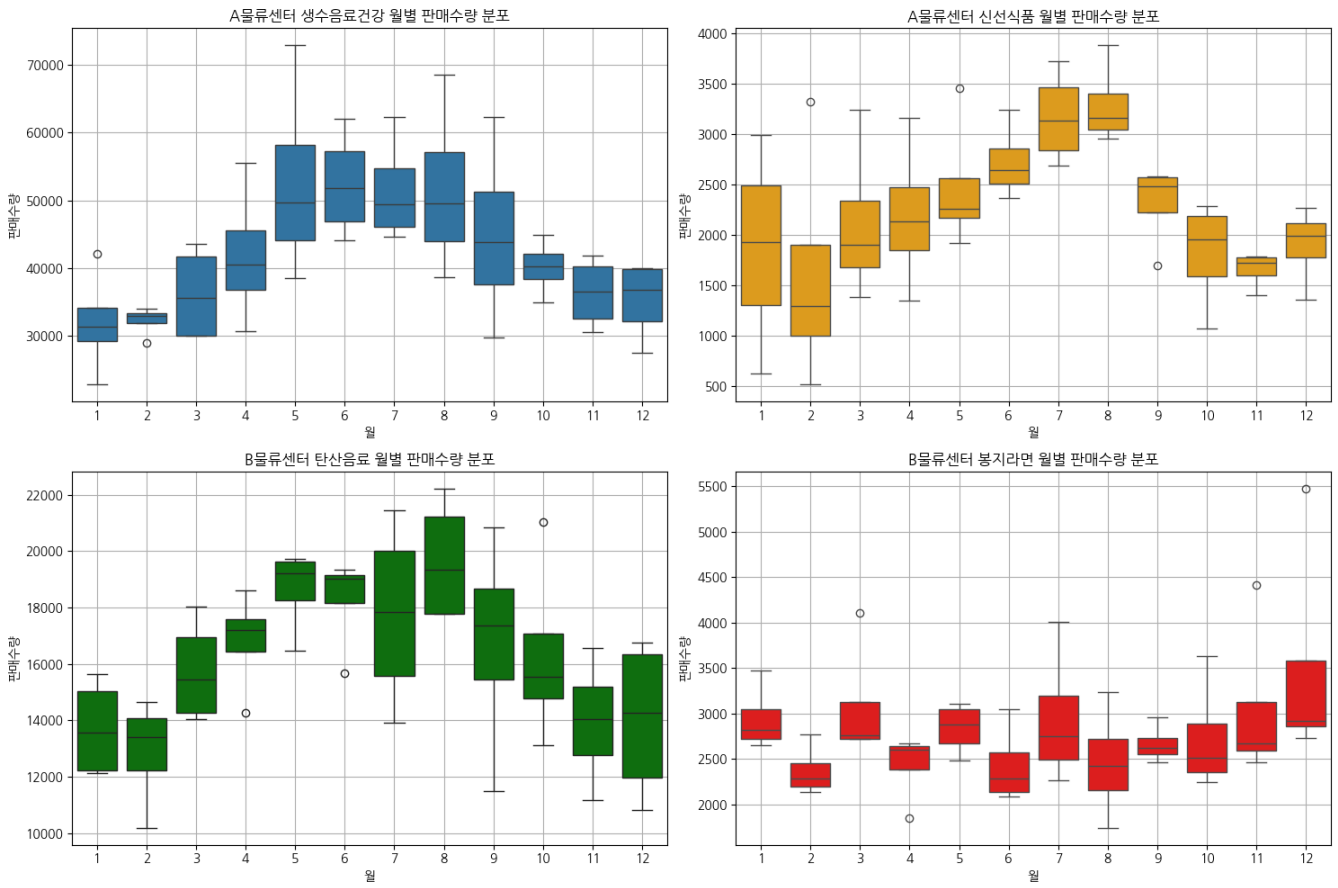
3. 데이터 탐색(EDA)

본 절에서는 판매 수량 데이터를 대상으로 시계열적 특성과 계절성을 탐색하고자한다. 분석대상은 물류센터A의 중분류 생수·음료·건강, 신선식품, 물류센터B의 소분류 탄산음료, 봉지라면이며, 시각화를 통해 월별 수요 패턴을 파악했다.

전체적으로 생수·음료·건강, 신선식품, 탄산음료 세 품목군에서 여름철에 판매량이 증가하는 계절성이 관찰되었다. 이는 기온 상승의 영향으로 해석된다. 반면, 봉지라면은 월별 변동이 비교적 불규칙적이며, 계절에 따른 패턴은 확인되지 않았다.

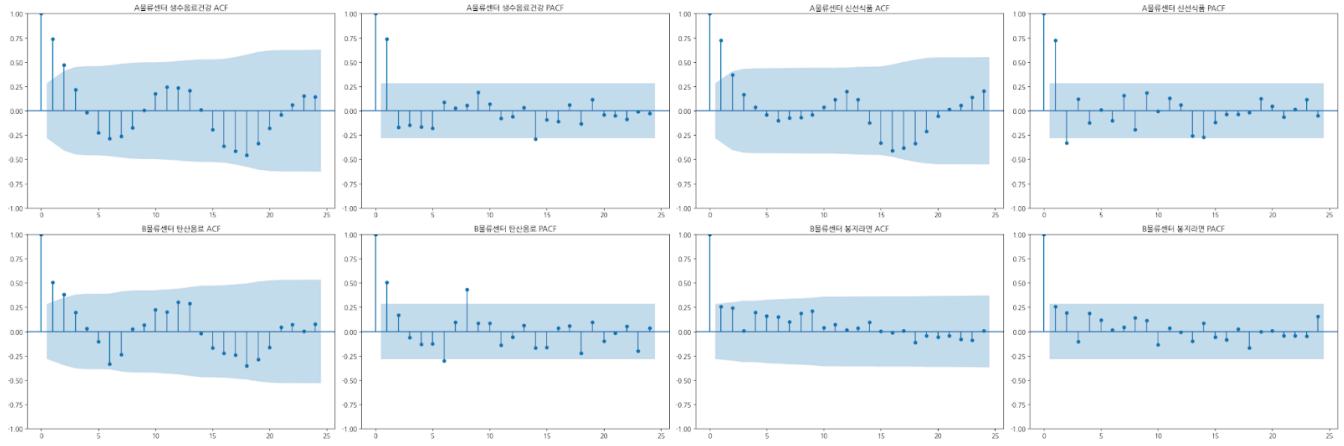


<그림1> 제품군별 월별 판매수량 추이



<그림2> 제품군별 월별 판매수량 분포

또한, 자기상관(ACF) 및 편자기상관(PACF)분석을 통해 품목군별 시계열의 통계적 특성을 검토했다. 그 결과 생수·음료·건강, 신선식품, 탄산음료의 세 품목군에서는 12개월 시차에서 약한 자기상관이 관찰되었다. 이는 전년도 동일 월의 판매량이 다음 해 동일 월의 판매량과 유사한 경향을 보임을 의미한다. 또한 직전 월의 판매량도 영향을 줬다. 반면, 봉지라면은 ACF와 PACF 모두에서 유의한 패턴이 나타나지 않아 비계절적 수요 구조로 판단했다.



<그림3> 품목군별 자기상관, 편자기상 함수

이러한 탐색 결과를 종합하면, 본 데이터는 품목군별 계절성의 강도와 변동성에 차이가 존재한다.
이에 따라 이후 모델링 단계에서는

- 계절성이 뚜렷한 품목군에는 Seasonal Naive, SARIMA계열 모형을 중심으로 적용하고,
- 비계절적 품목군에는 Naive, ARIMA모형을 우선적으로 적용했다.

또한, ACF와 PACF 분석은 단순한 계절성 탐색을 넘어 SARIMA모형의 차수 설정 및 계수추정에 사용될 수 있다.

4. 예측 모형 설정 및 적용 방법

4.1 모델 개요 및 선택 이유

EDA결과, 품목군별로 계절성의 정도가 다르게 나타났다. 이에 따라 본 연구에서는 단순모형(baseline)부터 계절, 외생요인 반영 모형까지 점진적으로 확장하는 구조로 모델링을 설계했다.

가장 먼저, Naive 및 Seasonal Naive모형은 직전 시점 혹은 전년도 동일 월의 판매량을 그대로 예측값으로 사용하는 단순 시점 기반 모형이다. 이들은 복잡한 파라미터 추정 없이 최근 패턴이 지속된다고 가정하며, 전체 분석의 베이스라인으로 설정했다.

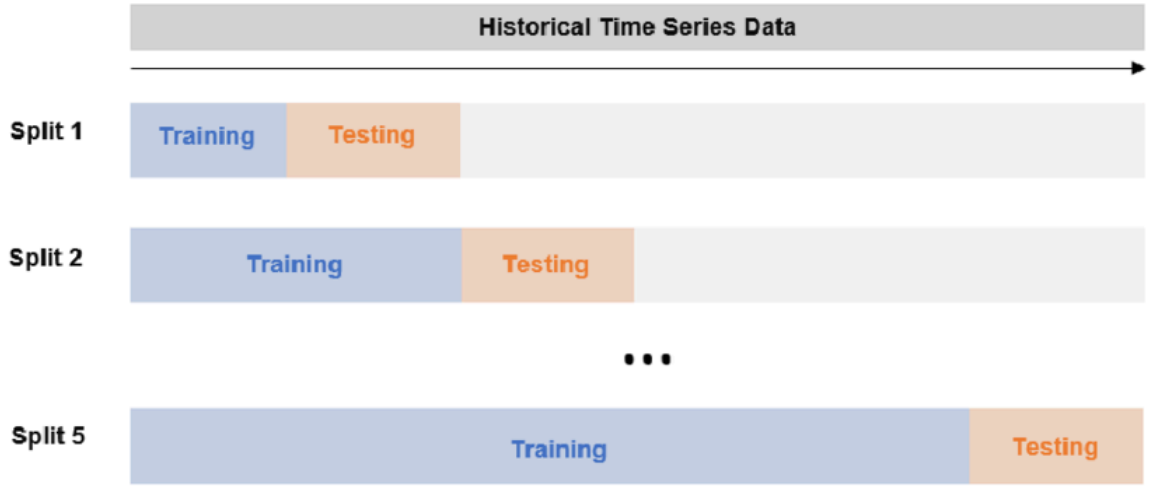
다음으로, SARIMA 모형은 시계열의 비계절성 성분과 계절 성분을 함께 반영하여 계절성과 추세를 동시에 고려한다. 계절성이 확인된 품목군에 대해 이 모형을 적용함으로써 계절적 수요 변동을 반영했다.

SARIMAX 모형은 SARIMA구조에 외생변수를 추가하여 기온, 공휴일 등 외부 요인이 수요에 미치는 영향을 함께 고려하도록 확장한 형태이다. 이를 통해 단순한 계절 주기뿐 아니라 환경적 요인에 따른 수요 변동을 정량적으로 반영할 수 있도록 하였다.

마지막으로, Prophet모형은 추세, 계절성, 공휴일효과를 비선형적으로 분해, 학습하는 모델로, 복잡한 수요 패턴 변화에 유연하게 대응할 수 있다. SARIMA보다 설정이 간단하고, 급격한 추세 전환 탐지가 빠른 장점이 있다.

4.2 모형 학습 및 검증 절차

모형의 예측 성능을 객관적으로 비교하기 위해 Rolling Forecast기반의 Expand Method를 적용했다. 이 방법은 학습 구간을 점진적으로 확장시키면서 과거 데이터를 이용해 미래를 예측하는 과정을 모사하는 검증 방식이다.
예시로, 초기 학습 구간을 2021년 1월부터 2022년 6월로 설정하고 2022년 7월부터 9월까지의 판매량을 예측하고 다음 반복에서는 2021년 1월부터 2022년 9월까지 확장하여 3개월 단위로 예측을 수행했다.



<그림4> Expand Method

이와 같은 절차를 통해 각 모형의 예측력을 시점별로 반복 검증함으로써 일관성과 안정성을 확보했다. 모형의 성능 평가는 RMSE를 기준으로 수행했다. RMSE는 예측오차의 제곱 평균의 제곱근으로, 오차의 크기가 클수록 지표 값이 민감하게 증가한다. 따라서 수요 급등·급락 구간이 존재하는 시계열 데이터의 예측 정확도 평가에 적합하다. 이 절차를 통해 각 모형의 예측 성능을 정량적으로 비교하고, 품목군별 가장 적합한 예측 모형을 도출했다.

5. 모델링 및 결과해석

모형별 파라미터는 ACF와 PACF분석을 통해 초기 차수를 탐색한 fold들의 평균 RMSE를 기준으로 각 품목군별 최적 조합을 선정했다. 비계절 차수와 계절 차수의 조합을 순차적으로 비교한 결과, 품목별로 약간 다른 계절성과 추세 특성이 반영되었다. 예를 들어 생수·음료·건강, 신선식품 품목군에서는 (1, 1, 1)x (0, 1, 1, 12) 탄산음료 품목군에서는 (0, 1, 1)x (0, 1, 1, 12) 봉지라면은 ARIMA(0, 1, 1) 구조가 가장 낮은 RMSE를 보였다.

SARIMAX 모형은 동일한 구조에 직전년도 평균기온 및 공휴일 여부를 외생변수로 추가하여 외부요인을 반영했다. 그러나 일부 품목군에서는 외생변수가 시계열 패턴과 뚜렷한 상관관계를 보이지 않아 오히려 노이즈로 작용하여 RMSE가 증가했다. 이는 월 단위 집계 과정에서 외생변수의 변동성이 완화되고, 품목별 기온 민감도 차이가 충분히 반영되지 못한것으로 판단 된다.

Prophet 모형은 시계열을 추세, 계절성, 휴일 효과로 분해하여 모델링은 진행했다. 월별 데이터 기준으로 푸리에 급수를 이용한 계절항을 추가하였으며, 추세 변화 민감도와 계절성 강도를 최적화 하기 위해 Grid Search 방식의 튜닝을 진행했다. 그 결과 품목군별로 서로 다른 파라미터 조합이 도출되었다,

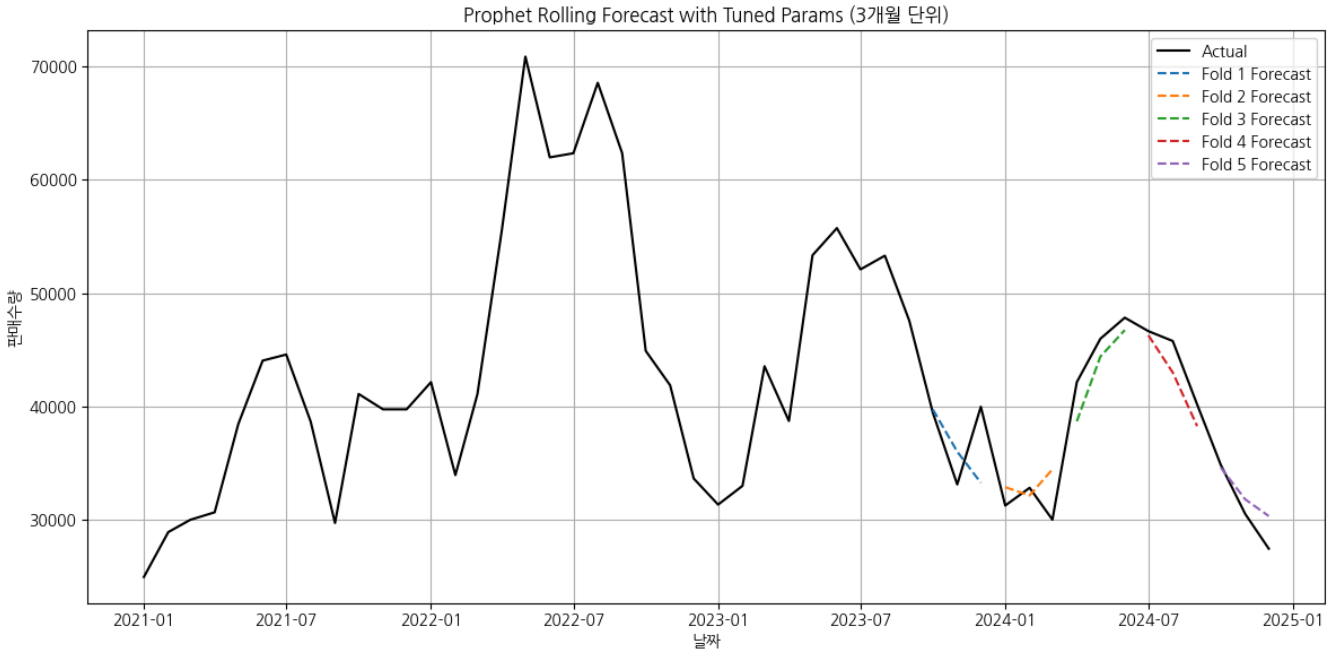
품목군	changepoint_prior_scale	seasonality_prior_scale	seasonality_mode	Fourier Order
생수·음료·건강	0.05	3.0	Multiplicative	3
신선식품	0.2	1.0	Additive	3
탄산음료	0.05	5.0	Additive	3
봉지라면	0.05	3.0	Multiplicative	7

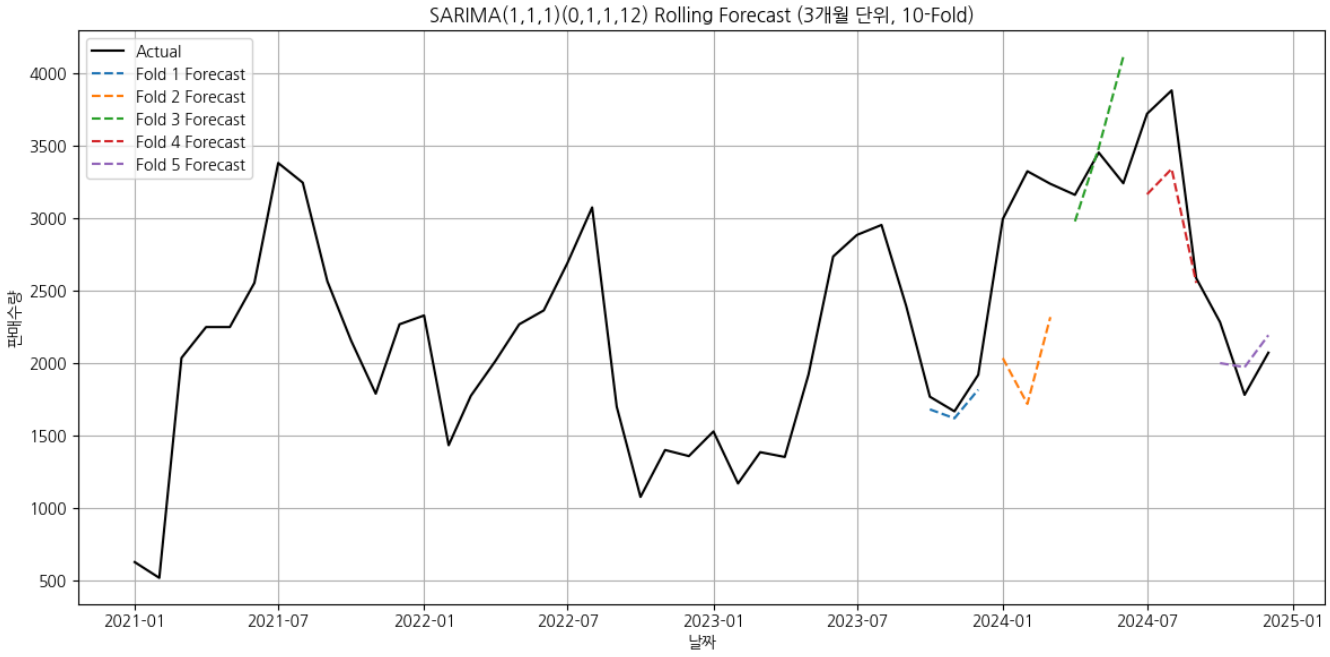
<표1> Prophet 모형 최적 파라미터 조합

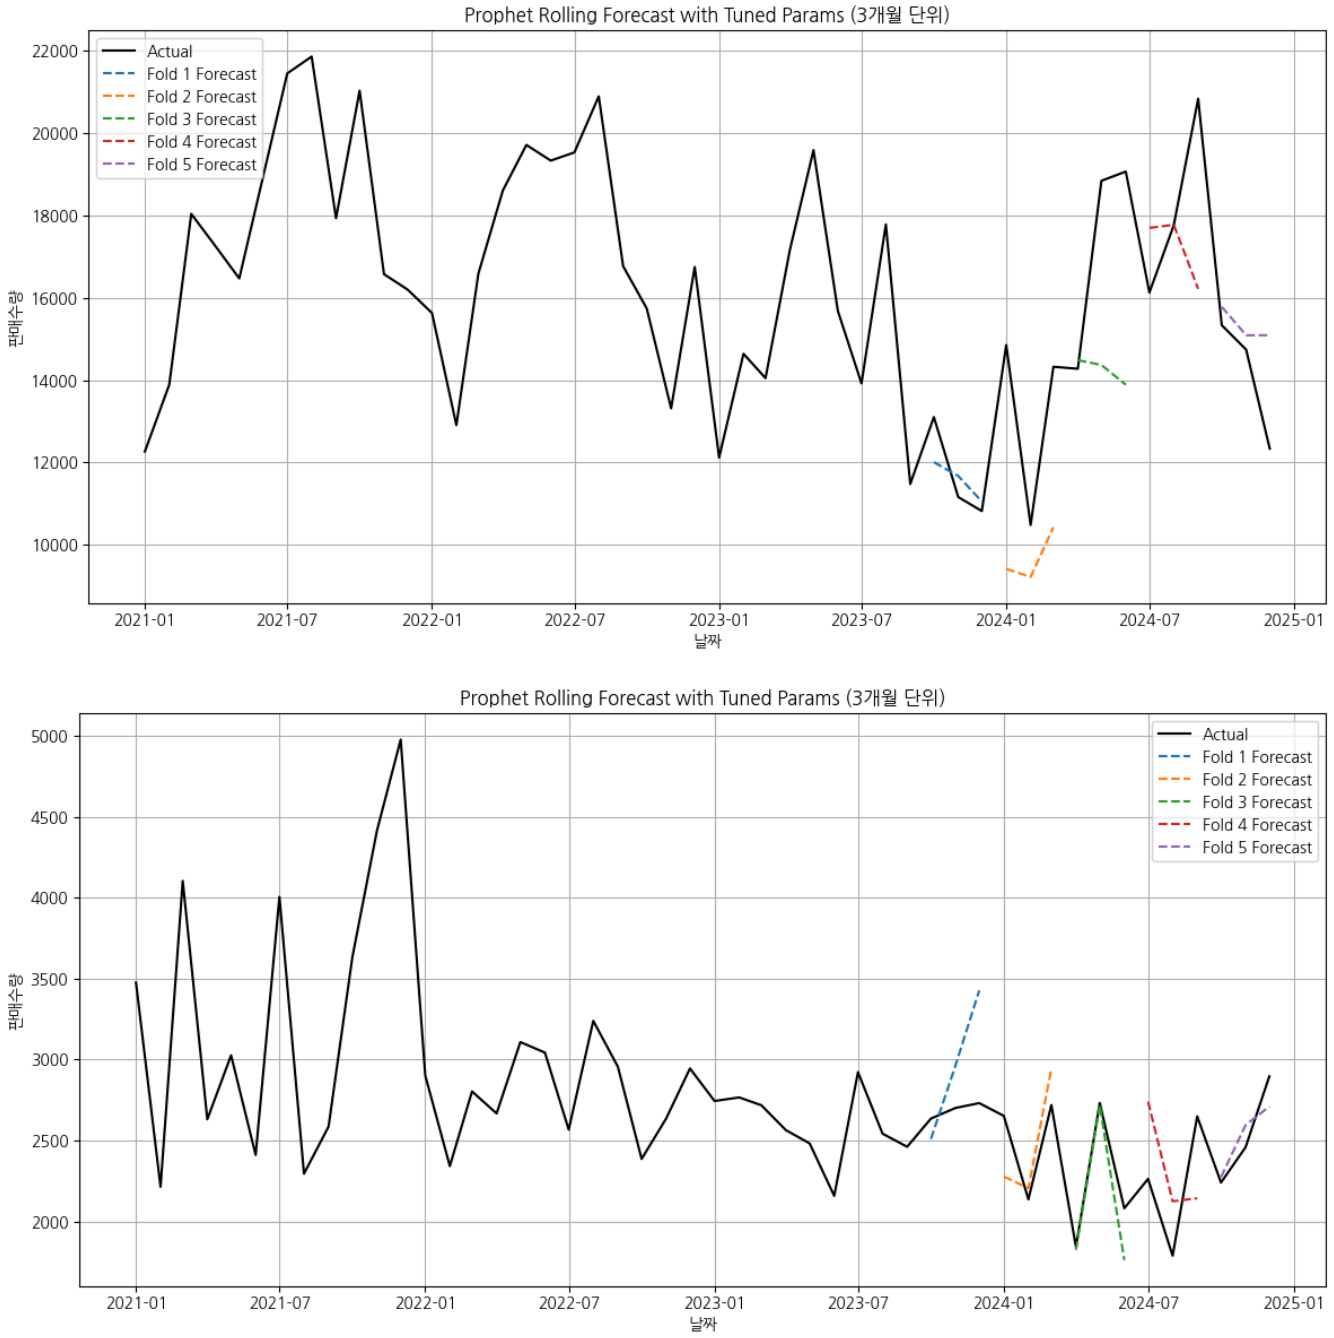
Prophet은 복잡한 파라미터 췌 과정 없이도 패턴을 자동 탐지할 수 있어 데이터 수가 제한적임에도 안정적인 성능을 보였다. 특히 세 제품군이 SARIMA 대비 RMSE가 개선되었으며, Grid Search를 통해 추세 민감도, 계절성 강도를 조정하여 더 최적화된 결과를 얻을 수 있었다.

품목군	Naive	Seasonal Naive	SARIMA	SARIMAX	ARIMA	Prophet	최적 모형
생수·음료·건강	–	7,205.00	4,607.00	5,604.00	–	**2,607.00**	Prophet
신선식품	–	966.14	**492.11**	709.82	–	958.70	SARIMA
탄산음료	–	3,544.50	3,027.00	4,257.00	–	**2,607.00**	Prophet
봉지라면	379.57	379.47	–	–	336.68	**291.37**	Prophet

<표2> 품목군별 최적 모형


Prophet Rolling Forecast with Tuned Params (3개월 단위)
Actual
Fold 1 Forecast
Fold 2 Forecast
Fold 3 Forecast
Fold 4 Forecast
Fold 5 Forecast
판매수량
날짜
70000
60000
50000
40000
30000
2021-01
2021-07
2022-01
2022-07
2023-01
2023-07
2024-01
2024-07
2025-01


SARIMA(1,1,1)(0,1,1,12) Rolling Forecast (3개월 단위, 10-Fold)
Actual
Fold 1 Forecast
Fold 2 Forecast
Fold 3 Forecast
Fold 4 Forecast
Fold 5 Forecast
판매수량
날짜
4000
3500
3000
2500
2000
1500
1000
500
2021-01
2021-07
2022-01
2022-07
2023-01
2023-07
2024-01
2024-07
2025-01



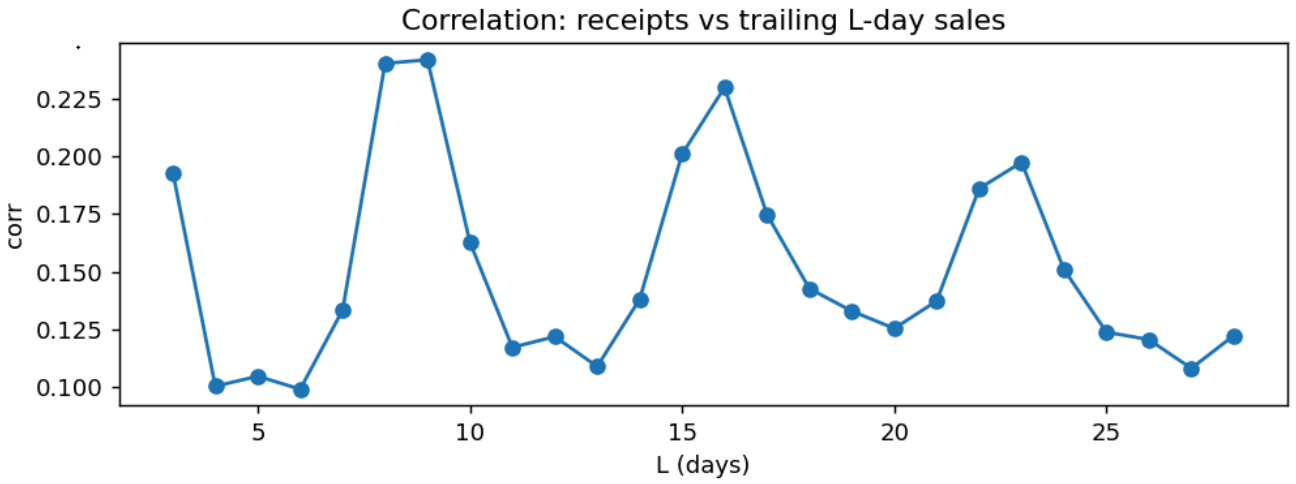
<그림5> 품목군별 예측모형 시각화

<매입 수량 예측>

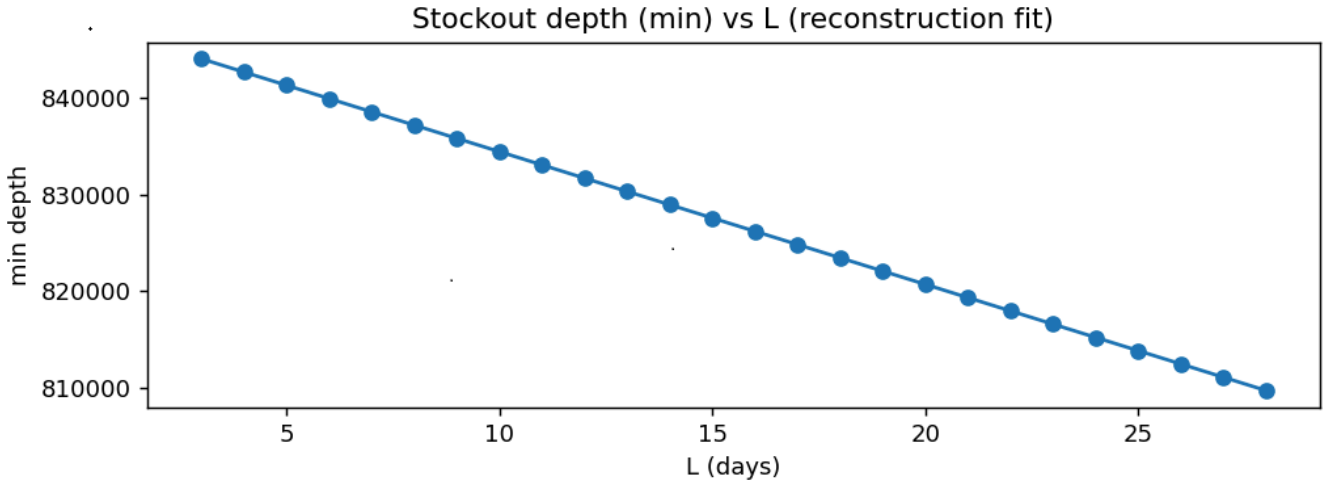
1. 리드타임(L) 및 발주주기(R) 추정

주어진 데이터에서 리드타임과 발주주기가 기재되어있지 않으므로, 매입/매출 데이터를 이용하여 리드타임과 발주주기를 추정하였다.

리드타임의 경우, 1일~30일의 후보를 두고, 직전 L일 판매합과 당일 입고량의 상관관계를 살펴보았다. 상관 최댓값 후보를 도출해냈다. 이후 후보 L마다 초기재고를 합리 범위에서 조정하며 품절일수/품절깊이 최소가 되는 L 채택하였다. 즉, "판매 → L일 후 입고" 패턴이 가장 일관된 L을 실제 운영 리드타임으로 간주한 것이다.



발주주기의 경우, 입고 이벤트일(입고>0) 사이 간격을 모두 계산하여 최빈값을 구하였다. 노이즈 제거를 위해 소량입고(하위 20% 이하)는 이벤트에서 제외하고, 최종 P는 최빈 간격을 앵커 {7,14,21,28,30} 중 가장 가까운 값으로 스냅하였다.



2. 변동계수 CV 계산

판매=수요로 가정하고 리드타임(L)과 발주주기(R)이 고정(보호기간 T=L+R 고정)이라고 보았다. 보호기간 T 동안의 누적수요 변동성을 직접 측정하기 위해, 일별 수요에서 T일 롤링 합을 만들고 그 분포로부터 **변동계수(CV=표준편차/평균)**를 계산했다. 극단값의 영향을 줄이기 위해 원본 CV와 윈저라이즈(분위수 절단) CV를 함께 산출하여 로버스트 지표로 활용했다.

2-1. A 물류센터 — 생수·음료·건강 / 신선식품

A 물류센터 품목은 뚜렷한 계절성이 나타나, 특정 월에 판매가 급증한 뒤 다시 조정되는 패턴을 보였다. 이에 따라 시기를 피크와 논피크로 구분했다.

- 생수·음료·건강: 피크 시기 5-8월
- 신선식품: 피크 시기 3, 6, 8월

향후 안전재고(SS%) 산정 시 시기별 차등 적용을 위해 피크 CV와 논피크 CV를 각각 계산하였다.

2-2. B 물류센터 — 봉지라면 / 탄산음료

B 물류센터 품목은 전반적으로 수요가 완만하고 큰 이상치가 없는 패턴이었다. 따라서 시기 구분 없이 공통

CV(pooled/common CV)를 적용해도 충분하다고 판단했다.

3. 서비스레벨(z) 결정

품목 별 목표 서비스 레벨을 설정하였다. 유통기한이 짧은 신선식품을 제외하고, 평시 97.5% (z=1.96), 성수기 99% (z=2.33)로 설정하였다. 신선식품의 경우, CV값이 크지만 폐기 리스크를 고려하여 서비스 수준을 평시 95% (z=1.65), 성수기 97.5% (z=1.96)로 설정하였다.

4. 안전재고 ss% 결정

목표한 서비스레벨을 기준으로, 평시와 성수기의 안전재고 비율(SS(%) = CV * z)을 선정하였다.

5. 초기재고(I) 추정

주어진 데이터에 실사 재고나 발주일이 나와있지 않으므로, 입고 및 출고 이력만으로 일별 재고를 재구성하려면 시작점이 필요하다. 따라서 평균일수요 * L로 근사 추정하였다. 이후 시뮬레이션을 안정화하고, 품절/적재고 타이밍 왜곡을 최소화할 수 있다.

6. On-hand, On-order, Backorder 반영한 최종 매입량 산출 시뮬레이션

	A	B	C	D	E	F	G
1	date	forecast	receipts	on_hand	on_order	backorder	order_placed
2	2025-01-01	91.49657	0	260.6434	1408.254	0	1408.254
3	2025-01-02	91.49657	0	169.1469	1408.254	0	0
4	2025-01-03	91.49657	0	77.6503	1408.254	0	0
5	2025-01-04	91.49657	0	0	1408.254	13.84627	0
6	2025-01-05	91.49657	0	0	1408.254	105.3428	0
7	2025-01-06	91.49657	1408.254	1316.757	0	105.3428	0
8	2025-01-07	91.49657	0	1225.261	0	105.3428	0
9	2025-01-08	91.49657	0	1133.764	640.476	105.3428	640.476
10	2025-01-09	91.49657	0	1042.268	640.476	105.3428	0
11	2025-01-10	91.49657	0	950.7711	640.476	105.3428	0
12	2025-01-11	91.49657	0	859.2746	640.476	105.3428	0
13	2025-01-12	91.49657	0	767.778	640.476	105.3428	0
14	2025-01-13	91.49657	640.476	1316.757	0	105.3428	0
15	2025-01-14	91.49657	0	1225.261	0	105.3428	0
16	2025-01-15	91.49657	0	1133.764	640.476	105.3428	640.476
17	2025-01-16	91.49657	0	1042.268	640.476	105.3428	0
18	2025-01-17	91.49657	0	950.7711	640.476	105.3428	0
19	2025-01-18	91.49657	0	859.2746	640.476	105.3428	0
20	2025-01-19	91.49657	0	767.778	640.476	105.3428	0
21	2025-01-20	91.49657	640.476	1316.757	0	105.3428	0
22	2025-01-21	91.49657	0	1225.261	0	105.3428	0

월합 예측을 일별 예측으로 배분한 뒤, 발주주기(R)와 리드타임(L), 보호기간 T=L+R, 안전재고율(SS%)을 이용해 기대 재고 흐름을 하루 단위로 시뮬레이션 하였다. 결과로 날짜별 on_hand / on_order / backorder / receipts / order_placed를 계산되고, 이를 통해 최종 매입량을 산출할 수 있다. 매일 수요를 차감하면서, R일마다 재고를 점검하고 한 번에 주문하는 로직으로 이루어진다.

6-1. 입고 반영

그날 도착 예정인 물량을 receipts로 받고 on_hand에 더한다. 받은 만큼 on_order는 줄어든다.

6-2. 수요(출고) 차감 및 품절 처리

일별 예측 수요 d(t)를 빼서 on_hand를 갱신한다. 재고가 모자라면 그 부족분이 당일 미이행이 되어 backorder 누계에 더해진다. On_hand는 0 아래로 내려가지 않게 clip된다.

6-3. 주문

발주일에는 앞으로 T+L+R일 동안의 예측수요 합계에 안전재고 비율(SS%)을 얹어 목표재고 S를 선정한다. 발주량(주문량)은 현재 손재고 I (on-hand), 미도착 주문 OO (on-order), 미납누적 BO (backorder)를 고려해 모자란 만큼만 주문한다. 다음의 수식에 따라 계산되며, 이는 리드타임 L일 후 입고 된다.

$S = DT \times (1+SS\%)$

$Q = \max(0, S-(I + OO - BO)$

6-4. 최종 월별 매입량

시뮬레이션에서 입고(receipts)는 주문일로부터 L일 후 도착분을 일 단위로 계산한다. 월별 매입량은 각 월에 실제로 입고된 수량의 합으로 산정한다. 전월에 발주한 물량이라도 해당 월에 도착하면 그 월 매입으로 집계하였다.

◦ 분석 결과

모형별 교차검증을 통해 도출된 최적 파라미터를 적용하여 감 품목군의 최종 예측을 수행했다. 예측은 2025년 1우러부터 2025년 3월까지의 3개월을 대상으로 진행되었으며, 직접 학습 구간의 모든 데이터를 이용하여 학습했다. Prophet모형이 전반적으로 안정적인 성능을 유지하며, 비선형적 패턴이 잘 반영된 것으로 보인다.

구분	2025-01	2025-02	2025-03
생수·음료·건강	27,923.88	27,276.15	**29,157.83**
신선식품	2,836.39	2,547.62	**3,054.58**
탄산음료	13,647.21	13,949.79	**15,679.39**
봉지라면	2,306.66	1,751.87	**2,391.94**

시뮬레이션을 통해 일별 예측 수요와, 실제 발주한 수량, 리드타임 경과 후 입고된 수량, on-hand / on-order / backorder 재고가 산출하였다. 이를 기반으로 각 월에 입고된 수량의 합을 통해 월별 매출 수량을 예측하였다.

날짜	생수 / 음료 / 건강	신선식품	봉지라면	탄산음료
2 5 년 1 월	34240.9	3328.131	2634.328	14294.4
2 5 년 2 월	27471.81	2567.403	1655.953	14541.71
2 5 년 3 월	23530.2	2853.075	2291.007	14237.91

◦ 활용방안

<모델의 활용방안 및 연구 방향성>

동적 안전재고(Dynamic Safety Stock) 도입:

과거 경험에 의존한 정적인 안전재고 방식에서 벗어나, 본 분석에서 도출된 월별 예측 판매량에 연동되는 '동적 안전재고'를 도입할 수 있다. 예를 들어, '신선식품'과 같이 폐기 리스크가 큰 품목은 비교적 낮은 서비스 수준(예: 90%)을, '생수/음료'와 같이 품절 기회비용이 큰 품목은 높은 서비스 수준(예: 97%)을 차등적으로 적용하여, 예측된 수요량에 맞춰 매월 최적의 안전재고 수준을 자동으로 계산하고 유지할 수 있다.

발주점(ROP) 자동화 및 최적 매입량 산출:

산출된 발주점(Reorder Point)을 시스템에 설정하여, 재고가 특정 수준 이하로 떨어질 때 자동으로 발주가 트리거되는 자동 발주 시스템을 구축할 수 있다. 또한, 최적 매입량을 매월 정확히 산출함으로써, 담당자의 주관적인 판단을 최소화하고 과잉/부족 재고를 원천적으로 방지할 수 있다.

계절성을 이용한 규모의 경제 효과:

여름에 수요가 상승하는 음료 품목군의 경우 많은 매입량이 필요하다. 또한, 유통기한이 큰 특징이 있으므로 특정 매입처에 주문량을 크게 가져가서 구매단가를 낮추는 전략을 구상해볼 수 있다.

<판매수량 예측 한계>

1. 데이터 기간 및 관측 단위 제약

충분한 장기 추세 및 비정상적 이벤트를 반영하기 어려웠다. 월 단위 집계는 단기 변동성을 평활화시키는 장점이 있으나 외생요인의 즉각적인 영향을 포착하기에는 한계가 존재했다.

2. 모든 품목군을 동일한 단변량 시계열로 처리

이는 품목 간 상관관계나 유사패턴을 고려하지 못하므로 유사한 수요 패턴을 보이는 제품군을 클러스터링 기반으로 분류하고, 군집별 맞춤 예측 모형을 적용하는 다차원접근이 필요하다 예를 들어 ADI, CV 지표를 활용하여 각 유형에 맞는(예: Croston, TSB 등)을 차별 적용하는 방식으로 확장할 수 있다.

3. 다차원 결정 요인 고려

기온, 공휴일을 사용하여 계절적 영향을 반영했으나, 신제품 출시, 프로모션 등 다차원적 결정 요인은 고려하지 못했다. 향후에는 지역, 제품 사이클 특성과 같은 변수를 통합하여 다변량 모형으로 확장할 필요가 있다.

1. 고정된 리드타임과 발주주기

현업에서는 리드타임이 변동되거나 부분선적으로 입고되는 일이 흔하지만, 현재 모델은 고정 리드타임·고정

발주주기를 가정하고 있어 입고 타이밍이 왜곡될 수 있다. 실제로는 리드타임/발주주기 데이터가 확보되는 것이 최선이지만, 데이터가 부족한 상황에서는 다음과 같은 보완이 필요하다.

- 리드타임을 확률분포로 모델링 + 부분선적 반영
  과거 입고 간격으로 리드타임 분포(예: 로그정규/경험분포)를 추정한 뒤, 발주마다 해당 분포에서 샘플링해 서로 다른 리드타임을 부여한다. 동시에 일정 확률로 주문량을 2~3회로 분할해 도착시키는 부분선적 로직을 추가한다.

이렇게 하면 지연·조기 도착을 자연스럽게 반영할 수 있어 on-order/receipts의 타이밍이 현실화되고, 그 결과 안전재고와 주문 의사결정이 과도하게 공격적이거나 지나치게 보수적으로 치우치는 현상을 완화할 수 있다.

2. 현실 제약 미반영 (MOQ/박스단위/예산/공간제약 등)

◦ 활용데이터 및 참고 문헌 출처 등

○ 활용 데이터명

A물류센터 매입 2021~2024 배포용.xlsx

A물류센터 매출 2021~2023 배포용.xlsx

A물류센터 매출 2024 배포용.xlsx

B물류센터 매입 2021~2024 배포용.xlsx

B물류센터 매출 2021~2023 배포용.xlsx

B류센터 매출 2024 배포용.xlsx

상품정보_가공식품(14,251).csv

상품정보_신선식품(38건).csv

○ 타기관 또는 민간 데이터 명 :

서울시 월누적 강수량, 서울시 월별 평균기온, 서울시 소비자물가지수(지출목적별) 통계

○ 사용한 라이브러리/툴 :

Pandas, Numpy, Matplotlib, Seaborn, Scikit-learn, Statsmodels, datetime, Prophet

본 연구의 분석은 Python 3.10 환경에서 수행되었으며, Jupyter Notebook을 개발 환경으로 사용했다.

○ 참고 문헌 및 자료 출처 :

김용철 외(2019), 「기상요인이 음료 소비에 미치는 영향 분석」, 한국식품유통학회지.

“The impact of systematic changes in weather on the supply and demand of beverages” (Keleş, Gómez-Acevedo, Shaikh, International Journal of Production Economics, 2018)

서은석. (2015). 정책적 안전재고의 비용 최적화 : 제록스 소모품 유통공급망 사례연구. 대한산업공학회지, 41(5), 511-520.